

Politique de mise à niveau du mode d'expédition pour les commandes à forte valeur

Plan de test A/B

DataCo — Équipe Data Science

1 Résumé Exécutif

DataCo connaît actuellement un taux de livraison en retard de 54,8 %, ce qui dégrade l'expérience client et entraîne des pertes financières mesurables. Les commandes livrées à temps génèrent un bénéfice moyen de 22,32 \$, tandis que les commandes en retard génèrent 21,54 \$, soit un écart de 0,78 \$ par commande. Cela représente un bénéfice annuel à risque de 77 015 \$. L'analyse des modes d'expédition montre que le mode *Standard Class* présente un taux de retard de 38,1 % pour les commandes dont le bénéfice dépasse 200 \$. Ce document décrit une expérimentation visant à évaluer si la mise à niveau automatique de ces commandes à forte valeur vers le mode *First Class* permet de réduire les retards de livraison et de récupérer une partie du bénéfice à risque.

2 Conception de l'Expérience et Hypothèses

Hypothèses

- **Hypothèse nulle (H_0)** : La mise à niveau du mode *Standard Class* vers *First Class* pour les commandes dont le bénéfice est supérieur à 200 \$ n'a aucun effet sur le taux de livraison en retard :

$$\mu_{\text{contrôle}} - \mu_{\text{traitement}} = 0$$

- **Hypothèse alternative (H_1)** : La politique de mise à niveau réduit le taux de livraison en retard d'au moins 5 points de pourcentage (effet minimal détectable, MDE) :

$$\mu_{\text{contrôle}} - \mu_{\text{traitement}} \geq 0.05$$

Configuration du Test

- **Unité de randomisation** : Commande individuelle.
- **Répartition** : 50 % contrôle / 50 % traitement.
- **Groupe contrôle** : Les commandes à forte valeur (bénéfice > 200\$) continuent d'être expédiées via *Standard Class* (situation actuelle, sans intervention).
- **Groupe traitement** : Les commandes à forte valeur sont automatiquement surclassées vers le mode *First Class* lors de la validation de la commande.

3 Analyse de Puissance et Taille d'Échantillon

La taille d'échantillon requise par groupe est obtenue à partir d'un test de comparaison de deux proportions :

$$n = \frac{2\bar{p}(1-\bar{p})(z_{1-\alpha/2} + z_{1-\beta})^2}{\delta^2}$$

avec les paramètres suivants :

Paramètre	Valeur
Taux de retard de référence (<i>Standard Class</i>)	$p = 38,1\%$
Effet minimal détectable (MDE)	$\delta = 5,0$ points de pourcentage
Niveau de signification (α)	5% (bilatéral)
Puissance statistique ($1 - \beta$)	80%
Taille d'échantillon requise par groupe	$n = 1\,509$ commandes
Taille d'échantillon totale	$2n = 3\,018$ commandes
Volume quotidien estimé	≈ 14 commandes/jour
Durée estimée du test	≈ 216 jours (7 mois)

4 Cadre des Métriques

Métrique Principale

Taux de livraison en retard — proportion des commandes pour lesquelles le délai réel d'expédition dépasse le délai prévu. Objectif : réduire ce taux d'au moins 5 points de pourcentage dans le groupe traitement.

Métriques Secondaires

- **Bénéfice moyen par commande (\$)** : Marge nette par commande. Objectif : maintenir ou augmenter cette métrique dans le groupe traitement.
- **Taux d'annulation des commandes** : Pourcentage de commandes annulées. Objectif : aucune différence statistiquement significative entre les deux groupes.

Métriques de Surveillance (Guardrails)

- **Coût moyen d'expédition (\$)** : L'écart de coût ne doit pas dépasser 15 \$ par commande surclassée afin de garantir que l'augmentation des tarifs d'expédition n'annule pas les gains de rentabilité.
- **Taux de retour** : Ne doit pas dépasser de plus d'un point de pourcentage le niveau observé dans le groupe contrôle.

5 Règles de Décision Statistique

Nous rejetterons H_0 et procéderons à un déploiement complet si les trois conditions suivantes sont satisfaites à la fin de l'expérimentation :

1. La valeur-p du test de comparaison de proportions est inférieure à 0,05.
2. L'intervalle de confiance à 95 % de la différence des taux de retard exclut zéro et se situe entièrement dans la région positive.
3. L'augmentation du coût moyen d'expédition ne dépasse pas 15 \$ par commande.

6 Suivi Intermédiaire et Critères d'Arrêt

Afin de limiter les risques, trois analyses intermédiaires seront réalisées lorsque 25 %, 50 % et 75 % de la taille d'échantillon cible auront été atteints. Une correction de Bonferroni est appliquée aux trois analyses, ce qui fixe le seuil de significativité intermédiaire à :

$$\alpha_{\text{intermédiaire}} = 0.0167$$

L'expérimentation sera arrêtée prématurément si l'une des conditions suivantes est observée :

- Le coût moyen d'expédition dans le groupe traitement dépasse celui du groupe contrôle de plus de 25 \$ par commande.
- Le taux d'annulation des commandes dans le groupe traitement augmente de plus de 3,0 % par rapport au groupe contrôle.